

Estado del proyecto Capstone

Traspaso para la Evaluación 3 — Informe de avance

Proyecto: *Quedar fuera teniendo puntaje* — revisión del proceso de Admisión a la Educación Superior 2026
Integrantes: Daniela Contreras · Emanuel Nicklichen **Diplomado en Ciencia de Datos Aplicada · UTFSM · INF074H**
Fecha: 20 de septiembre de 2026

1. Dónde estamos, en una página

La pregunta. En el proceso de Admisión 2026, 189.399 personas postularon y 27.492 no quedaron seleccionadas en ninguna de sus preferencias. El proyecto pregunta cuántas de ellas tenían puntaje suficiente para haber entrado a algún programa con vacantes no cubiertas, y si esa proporción difiere según la dependencia del establecimiento del que egresaron o su nivel socioeconómico.

Las fechas que vienen.

Entrega	Fecha	Formato	Peso
Presentación oral	martes 22 de septiembre, clase 8	PDF de slides, subido antes de la clase	50%
Informe escrito	viernes 25 de septiembre	PDF, máximo 7 páginas	50%

La Evaluación 3 vale 25% del módulo.

Estado actual.

Análisis	Cerrado. Ocho notebooks ejecutados, cifras congeladas
Modelo	Listo. Dos logísticas y dos Poisson, con intervalos
Slides	Por armar
Informe	Por escribir

La rúbrica formal de esta evaluación todavía no se publica. Todo lo que sigue se construyó contra el enunciado `avance_capstone.md`.

2. De dónde venimos: la Evaluación 2

2.1 Lo que se entregó

Seis notebooks, uno por criterio de la rúbrica, todos ejecutados de principio a fin.

Notebook	Contenido
S0 Entorno	Versiones, verificación de fuentes, índice del entregable
S1 Calidad	Las cinco tablas, faltantes disfrazados, duplicados, dominios, merges
S2 Descriptiva	Centro, dispersión, forma, atípicos
S3 Bivariado	Correlaciones, grupos, contingencia, y el cálculo de alternativa alcanzable
S4 Visualización	Cuatro gráficos de tipos distintos
S5 Hallazgos	Cinco hallazgos y el modelo propuesto

2.2 Decisiones metodológicas cerradas

Esto es lo que **no hay que volver a discutir**. Cada una está documentada en su notebook con la evidencia que la sostiene.



Tema	Decisión
Ceros en CLEC_MAX , MATE1_MAX , MATE2_MAX , HCSOC_MAX , CIEN_MAX	Son faltantes disfrazados de “no rindió”, no desempeño. La escala parte en 100
PTJE_PREF	Llega como texto con coma decimal. decimal="," de pandas no basta si la columna trae blancos: hay que hacer <code>.str.replace(",",".")</code> antes de <code>to_numeric</code>
Blanco en PTJE_PREF	131.859 casos (7,78%). Partición exacta con ESTADO_PREF : tienen puntaje solo los estados 24, 25 y 26; el resto son anulaciones
ESTADO_PREF = 26	Es “seleccionado en preferencia anterior”, o sea la preferencia no se evaluó . No contarlo como selección
INGRESO_PERCAPITA_GRUPO_FA = 99	“Prefiere no responder” (27,61%). No es un decil
DEPENDENCIA en blanco	3.200 inscritos (1,00%) sin establecimiento de egreso registrado. Mismo grupo que los sin RBD , sin comuna y sin unidad educativa
HABILITACION_POST = 2	Sí habilita: es la excepción por estar en el 10% superior de notas. Habilitados son 242.379, no los 241.766 que cita la formulación
Ponderación Historia / Ciencias	No se suman: son un cupo único que se llena con el mejor puntaje entre ambas. Corrige de 1.411 a 10 los programas que no suman 100%
Los 10 programas artísticos restantes	Exigen prueba especial no capturada por la base de oferta. Es limitación de cobertura, no error del dato
Extranjeros sin NEM chileno	DEMRE redistribuye proporcionalmente el peso de NEM y Ranking entre las demás pruebas. No les asigna cero
Llave única de la base de postulantes	(MRUN, ORDEN_PREF, TIPO_PREF) . Sin TIPO_PREF aparecen 280.569 falsos duplicados, porque se puede postular a la misma carrera por vía regular y por cupo de género
PTJE_PREF sobre 1000	25.845 casos, todos de la vía PACE, por bonificación. Por eso los cortes se calculan solo sobre TIPO_PREF = REGULAR
Corte real de un programa	Mínimo puntaje ponderado entre sus seleccionados por vía regular (ESTADO_PREF = 24)

2.3 El activo metodológico principal

La reconstrucción del puntaje ponderado se validó contra **1.328.381 puntajes oficiales** y reprodujo el **99,96%** con error menor a 0,5 puntos. De las 472 discrepancias, 407 (86,2%) corresponden a las carreras con prueba especial.

Esto es lo que permite calcular el puntaje de un estudiante en un programa al que **no** postuló, que es la operación central del proyecto.

2.4 Lo que quedó débil

Autocrítica del propio trabajo, detectada al preparar esta etapa:

- **El hallazgo 3 estaba mal referido.** El promedio de 713,4 puntos del grupo “sin alternativa” se calculó sobre 4.405 estudiantes, no sobre los 7.156 del grupo completo: los otros 2.751 no tienen puntaje que promediar porque no tenían ningún programa candidato. Corregido en la Sección 6.
- **La hipótesis nunca se contrastó como fue escrita.** La formulación compara Particular Pagado contra establecimientos públicos (Corporación Municipal, Municipal y SLEP). Lo que se hizo fue comparar las seis dependencias por separado y hablar del “resto”. Corregido en la Sección 7.
- **La dimensión socioeconómica quedó sin responder.** El decil se cruzó con los puntajes, pero nunca con el resultado del proyecto. Corregido en la Sección 7.
- **La explicación del hallazgo 2 era una conjetura.** Se afirmaba que Particular Pagado tiene menos sustitutos disponibles, sin medirlo. Ahora está medido.

3. Qué pide la Evaluación 3

Lo nuevo y obligatorio es el modelo. La Evaluación 2 pedía decir qué modelo se imaginaba ajustar; esta pide ajustarlo. Aparece en los dos formatos: punto 4 de la presentación y punto 5 del informe.

El resto de lo que pide ya existía en los seis notebooks y solo hay que seleccionarlo y comunicarlo.

Criterios declarados: claridad del problema y los objetivos; calidad del tratamiento de datos; solidez de los hallazgos y su evidencia; lectura estadística correcta (incertidumbre, asociación, causalidad); y calidad de la comunicación, incluido el cumplimiento de formato y extensión.

El código no va en el informe: se adjunta el notebook o el link al repositorio, con las mismas condiciones de reproducibilidad de la Evaluación 2.

4. Qué se construyó este fin de semana

4.1 Sección 6 — Base de análisis

El problema que resuelve. En la Evaluación 2 el cálculo de alternativa alcanzable se reconstruyó dos veces, en S3 y en S4. Funcionaba, pero cada reconstrucción es una oportunidad de que dos notebooks reporten cifras distintas para lo mismo.

Qué hace. Calcula una sola vez y guarda `data/processed/base_no_seleccionados.csv`: una fila por cada uno de los 27.492, con 16 columnas. Todo lo que viene después lee ese archivo.

Variables nuevas que introduce:

Variable	Qué es
<code>estado3</code>	Tres estados en vez de dos: con alternativa, con candidatos sin alcanzar, sin candidatos evaluables
<code>grupo_hipotesis</code>	Particular Pagado / Público / Otro, para contrastar la hipótesis como fue escrita
<code>ptje_obligatorias</code>	Promedio de <code>CLEC_MAX</code> y <code>MATE1_MAX</code>
<code>n_oportunidades</code>	Cuántos programas candidatos tiene en su área de interés
<code>n_carreras_distintas</code>	Amplitud real del interés: cuántos nombres de carrera distintos puso en su lista
<code>mejor_margen</code>	Máxima distancia entre su puntaje y el corte
<code>n_supera_con_empate</code>	Versión con <code>>=</code> en vez de <code>></code> , para el análisis de sensibilidad

Por qué `ptje_obligatorias` y no otro puntaje. Es el criterio que el propio DEMRE usa para determinar la habilitación, y no depende de qué programas eligió el estudiante. Un puntaje ponderado cambiaría según el programa y arrastraría la construcción del resultado hacia el modelo.

Por qué “Otro” existe. La hipótesis nombra Particular Pagado y Público (Corporación Municipal, Municipal, SLEP). Corporación de Administración Delegada y Particular Subvencionado no están en ninguno de los dos lados: aparecen en todos los descriptivos por dependencia, pero no entran al contraste. La hipótesis no se redefine después de ver los resultados.

4.2 Sección 7 — Contrastes y primer modelo

Cinco análisis, todos sobre el mismo CSV.

a) El resultado en tres estados

Estado	Estudiantes	%
Con alternativa alcanzable	20.336	73,97%
Con candidatos, sin alcanzar ninguno	4.405	16,02%
Sin ningún candidato evaluable	2.751	10,01%

Entre quienes tenían candidatos, los que **no** alcanzaron ninguno promedian 713,4 puntos contra 619,7 de los que sí. El puntaje alto no protege: apunta más arriba.

b) El contraste de la hipótesis

Grupo	N	Con alternativa	IC 95%
Particular Pagado	2.601	56,82%	[54,91 – 58,72]
Público	8.792	78,88%	[78,01 – 79,72]

Diferencia: **-22,06 puntos porcentuales**. Razón de odds 0,352. Los intervalos no se traslapan.

La hipótesis afirmaba lo contrario. **No se sostiene, y el resultado corre en dirección opuesta.**

c) El resultado por decil de ingreso

Plano entre los deciles 1 y 8 (banda de 71,7% a 77,4%, con intervalos que se traslapan casi todos), y una caída en el extremo: el decil 10 llega a **61,6%**. Los 8.232 que no informan ingreso se reportan aparte (73,1%) y no se imputan.

d) El primer modelo: regresión logística

Modelo	Particular Pagado vs Municipal	IC 95%	p
Sin ajustar	OR = 0,333	[0,299 - 0,371]	<0,001
Ajustado por decil y puntaje	OR = 1,033	[0,909 - 1,174]	0,618

El efecto desaparece. El intervalo contiene el 1.

Lo que queda es el puntaje: $OR = 0,993$ por punto. A **mayor** puntaje, **menor** probabilidad de tener una alternativa alcanzable. El pseudo R^2 sube de 0,016 a 0,116.

Traducido a probabilidades, fijando a todos en el mismo decil y puntaje, las seis dependencias quedan entre **77,2% y 81,1%**. La brecha de 23 puntos se cierra.

e) El mecanismo: cuántas alternativas existen

	Particular Pagado vs Municipal
Sin ajustar	IRR = 0,521, IC [0,489 - 0,554]
Ajustado por puntaje y amplitud de lista	IRR = 0,893

En promedio, un estudiante de Particular Pagado evalúa 11,3 programas candidatos contra 21,7 de uno municipal: **la mitad**. Al controlar por puntaje y por cuántas carreras distintas puso en su lista, la mayor parte se explica, pero queda un remanente cercano al 11%.

Se usó Poisson con errores estándar robustos porque el conteo está fuertemente sobredisperso (varianza 450 contra media 17).

f) Sensibilidad

Cambiar `puntaje > corte` por `puntaje >= corte` mueve **un caso** de 27.492. El resultado no depende del criterio de empate.

4.3 El resultado que cambia la narrativa

En la Evaluación 2 la historia era: *la hipótesis se invierte, y probablemente sea porque Particular Pagado persigue carreras con menos sustitutos.*

Ahora son tres pasos y el orden importa:

1. **Tres de cada cuatro tenían dónde ir.** El problema existe y está cuantificado.
2. **La hipótesis se invierte.** 56,8% contra 78,9%, al revés de lo esperado.
3. **Pero no es la dependencia: es el puntaje.** Al comparar estudiantes con el mismo decil y puntaje, las seis dependencias se alinean. Los de Particular Pagado promedian 722,5 puntos contra 541,9 de los municipales; apuntan a carreras más selectivas, y son esas las que no dejan cupos sin llenar.

Esto no significa que la dependencia no importe. El puntaje no es un factor ajeno que hubo que descontar: es el canal por el que opera la diferencia. En términos de la clase 4, es un **mediador**, no un confusor. La conclusión correcta es que la menor proporción de alternativas en Particular Pagado se explica por el puntaje y el nivel socioeconómico de esos estudiantes, no por un efecto del tipo de establecimiento independiente de ellos.

5. De dónde sale cada cifra

Cifra	Origen
320.087 inscritos · 189.399 postulantes · 161.907 seleccionados · 27.492 sin selección	S1 y S7
99,96% de validación del puntaje ponderado	S3

73,97% con alternativa · 16,02% · 10,01%	S6 y S7
56,82% vs 78,88%, diferencia de 22 pp	S7
Por decil, 77,0% a 61,6%	S7
OR 0,333 → 1,033	S7
IRR 0,521 → 0,893	S7
242.379 habilitados	S2

Todas las cifras de la presentación y del informe deben salir de esta lista. Si aparece un número que no está acá, hay que poder apuntar a la celda que lo produce.

6. Lo que viene

6.1 Presentación oral — 8 slides, 10 minutos

#	Slide	Estado	Gráfico
1	El problema y la pregunta	Listo, de la formulación	Embudo
2	Los datos y la población	Listo, de S1	—
3	Cómo se define una alternativa + validación 99,96%	Listo, de S3	—
4	Hallazgo 1: los tres estados	Listo, de S7	Barras horizontales
5	Hallazgo 2: la hipótesis al revés	Listo, de S7	Barras con IC
6	Hallazgo 3: el resultado por decil	Listo, de S7	Línea con IC
7	El modelo: observado contra ajustado	Listo, de S7	Barras agrupadas
8	Qué se puede y qué no concluir + limitaciones	Por redactar	—

Ambos integrantes exponen. El tiempo se controla: conviene ensayar.

6.2 Informe escrito — 7 páginas

	Página	Contenido
	1	Resumen de 150 palabras, objetivos e hipótesis
	2	Los datos: fuentes, tablas, variables y calidad, en una tabla
	3	Definición operacional de alternativa y reconstrucción del ponderado
	4	Hallazgos 1 y 2
	5	Hallazgo 3 y mecanismo
	6	El modelo: razones de odds, intervalos, probabilidades, qué permite concluir
	7	Limitaciones, próximos pasos, bibliografía y declaración de IA

El resumen se escribe **al final**, cuando el resto ya está.

6.3 Lo que se declara como limitación y no se resuelve

Escribir esto bien vale más puntos que resolverlo a medias, y el informe tiene una sección para ello.

- **Vacante no cubierta no es lo mismo que cupo disponible durante la selección.** El cálculo usa `VAC_1ER - matriculados`, y la matrícula ocurre *después* de la asignación. Un programa puede terminar con matrícula baja porque los seleccionados no usaron su cupo.

- **El área de interés se define por igualdad exacta del nombre de carrera.** Carreras equivalentes con nombres distintos no se reconocen como sustitutas, y la misma carrera en otra región se trata como sustituto perfecto.
- **No se verificaron todos los requisitos de los programas,** solo el puntaje contra el corte.
- **La dimensión geográfica no se evaluó.**
- **El modelo describe asociaciones, no causalidad.**

7. Preguntas previsibles

¿Entonces la dependencia importa o no? La logística dice que no y el Poisson dice que sí.

Son dos preguntas distintas. La dependencia no tiene efecto propio sobre *alcanzar* una alternativa cuando se comparan estudiantes con el mismo puntaje y decil. Sí tiene un efecto pequeño y residual sobre *cuántas alternativas existen* en su área de interés.

¿Por qué no juntaron todo lo no-pagado en un solo grupo público?

Porque la hipótesis fue escrita en la formulación definiendo público como Corporación Municipal, Municipal y SLEP. Redefinirla después de ver los resultados sería acomodar la prueba a la respuesta.

¿El 73,97% no está inflado?

Es el porcentaje que superaba el corte observado de al menos un programa de igual carrera cuya matrícula final quedó bajo las vacantes informadas. No afirma que ese cupo estuviera disponible en el momento de la asignación; esa es la primera limitación declarada.

Controlar por puntaje, ¿no elimina justamente el mecanismo?

Sí, en parte, y por eso se reporta de las dos formas. El puntaje es un mediador: los de Particular Pagado tienen más puntaje y por eso apuntan más alto. Mostrar el modelo crudo y el ajustado juntos es lo que permite ver que la diferencia opera por esa vía.

¿Por qué una logística y no una regresión lineal?

La variable respuesta es binaria. Una lineal podría predecir probabilidades fuera del rango 0-1 y no representa la forma de la relación.

8. Archivos del proyecto

Todos en `proyecto_paes_2026/notebooks/`, ejecutados de principio a fin.

```
Evaluación 2: S0_Entorno · S1_Calidad · S2_Descriptiva
              S3_Bivariado · S4_Visualizacion · S5_Hallazgos

Evaluación 3: Evaluacion_3_S6_Base -> genera el CSV
              Evaluacion_3_S7_Modelo -> lee el CSV, no recalcula
```

Los datos crudos van en `data/raw/2026/` y no se versionan. La tabla derivada queda en `data/processed/base_no_seleccionados.csv`.

Dependencia nueva: `statsmodels`, agregada en septiembre de 2026 por el uso de regresión logística y de Poisson. Registrada en `pyproject.toml` y `uv.lock`.